

Atividade Prática 1 – Aprendizagem de Máquina

Comparação de Estratégias de Classificação de Imagens no CIFAR-10

Isabella Vanderlinde Berkembrock

21 de junho de 2026

Disciplina: Aprendizagem de Máquina **Dataset:** CIFAR-10 **Código:**
<https://github.com/berkembrockisabella/cifar10-deep-learning-strategies.git>

Resumo

Este relatório descreve a implementação e avaliação de cinco estratégias de classificação de imagens no CIFAR-10: (1) CNN treinada do zero; (2) extração de características com redes pré-treinadas e classificador MLP; (3) *fine-tuning* da ResNet50; (4) *fine-tuning* com variações de *data augmentation*, camada de *pooling* e otimizador; e (5) *fine-tuning* do EfficientNetV2B0 (bônus). A melhor acurácia obtida foi de **90,82%**, alcançada pela Estratégia 4 na configuração GAP + SGD + *augmentation* básica.

1 Configuração Experimental

O CIFAR-10 [1] é composto por 60.000 imagens coloridas de 32×32 pixels distribuídas em dez classes, com divisão padrão de 50.000 para treino e 10.000 para teste. Nas estratégias que utilizam redes pré-treinadas no ImageNet, as imagens foram redimensionadas para 96×96 pixels via interpolação bilinear, mantidas em `uint8` até o momento de uso para reduzir o consumo de memória, com conversão para `float32` e normalização específica de cada *backbone* realizada imediatamente antes do treinamento.

Todas as estratégias baseadas em redes neurais utilizaram *EarlyStopping* (*patience* = 5, monitorando acurácia de validação com `restore_best_weights`) e *ReduceLROnPlateau*

(fator 0,5, *patience* = 3).

Estratégia 1 – CNN do zero

Arquitetura com três blocos convolucionais (32, 64 e 128 filtros), cada um seguido de *BatchNormalization* e *Dropout* (0,25), e classificador denso de 256 unidades com *Dropout* (0,5). Treinamento com Adam ($lr = 10^{-3}$), *batch* de 64, até 50 épocas, validação de 10%.

Estratégia 2 – Extração de características

MobileNetV2 e ResNet50 com pesos congelados utilizadas como extratoras (*pooling*='avg'), com classificador MLP selecionado via *GridSearchCV* (3 *folds*; espaço de busca: camadas ocultas {(256,), (512,), (256, 128)} e ativações {ReLU, logística}).

Estratégia 3 – Fine-tuning ResNet50

Fase 1: base congelada, topo treinável – GAP + Dense(256) + Dropout(0,5) + softmax – com Adam ($lr = 10^{-3}$), até 20 épocas. **Fase 2:** camadas a partir do índice 140 descongeladas, Adam ($lr = 10^{-5}$), *batch* de 32, até 20 épocas adicionais.

Estratégia 4 – Fine-tuning com data augmentation (MobileNetV2)

Mesmo pipeline de duas fases da Estratégia 3. Quatro configurações avaliadas para responder às questões abertas:

- **4a** – Flatten vs. GlobalMaxPooling2D (GMP): impacto da camada de redução espacial.
- **4b** – Adam vs. SGD (*momentum* 0,9): impacto do otimizador na Fase 2.
- **4c** – *Augmentation* básica vs. agressiva: básica com rotação $\pm 15^\circ$, translação 10%, *flip* e *zoom* 10%; agressiva com rotação $\pm 30^\circ$, translação 20%, *zoom* 20%, *shear* 0,1 e variação de brilho [0, 8; 1, 2].

Estratégia 5 – Fine-tuning EfficientNetV2B0 (bônus)

Fase 1 com base congelada e topo treinável – GAP + Dense(256) + Dropout(0,3) + softmax – com Adam ($lr = 10^{-3}$), 10 épocas. Fase 2 com os 20% superiores das camadas descongelados, Adam ($lr = 10^{-5}$), 15 épocas.

2 Resultados

A Tabela 1 consolida os resultados de todas as configurações avaliadas.

Tabela 1: Acurácia e F1 macro no conjunto de teste. Melhor resultado em negrito.

Est.	Variante / Configuração	Acurácia (%)	F1 macro (%)
1	CNN treinada do zero	86,19	86
2	Feature Ext. MobileNetV2 + MLP	80,81	81
	Feature Ext. ResNet50 + MLP	86,84	87
3	Fine-tuning ResNet50	89,91	90
4	Flatten + Adam + <i>AugBasica</i>	90,13	90
	GMP + Adam + <i>AugBasica</i>	90,11	90
	GAP + SGD + <i>AugBasica</i>	90,82	91
	GAP + Adam + <i>AugAgressiva</i>	89,83	90
5	Fine-tuning EfficientNetV2B0	89,05	89

A Tabela 2 detalha as métricas por classe para a melhor configuração (Estratégia 4, GAP + SGD + *AugBasica*).

Tabela 2: Métricas por classe – Estratégia 4, GAP + SGD + *AugBasica* (90,82%).

Classe	Precisão (%)	Revocação (%)	F1 (%)
Avião	92	91	91
Automóvel	96	95	96
Pássaro	92	89	91
Gato	84	78	81
Cervo	88	92	90
Cachorro	86	84	85
Sapo	93	94	94
Cavalo	92	92	92
Navio	93	95	94
Caminhão	91	97	94
Macro avg	91	91	91

3 Discussão

Estratégia 1 vs. transferência de aprendizado. A CNN do zero atingiu 86,19%, resultado expressivo para uma arquitetura sem conhecimento prévio, mas inferior a todas as abordagens de transferência com *fine-tuning*, que partem de representações já discriminativas aprendidas no ImageNet.

Questão 2a – MobileNetV2 vs. ResNet50 como extratora. A ResNet50 superou a MobileNetV2 em 6,03 p.p. (86,84% vs. 80,81%) na modalidade de extração estática. A diferença reflete a maior capacidade representacional da ResNet50, cujos 50 blocos residuais geram *features* mais discriminativas que as convoluções *depthwise-separable* da MobileNetV2 – projetadas para eficiência, não para qualidade máxima de representação.

Questão 4a – Flatten vs. GlobalMaxPooling2D. A diferença foi de apenas 0,02 p.p. (90,13% vs. 90,11%), indicando efeito marginal da estratégia de redução espacial no contexto de *fine-tuning* com *augmentation*.

Questão 4b – Adam vs. SGD. O SGD com *momentum* (0,9) superou o Adam em 0,71 p.p. (90,82% vs. 90,11%), resultando na melhor acurácia geral. Ao partir de pesos já bem inicializados pelo pré-treinamento, o SGD navega o espaço de parâmetros com menor risco de convergir para mínimos rasos de baixa generalização, o que é consistente com evidências da literatura [2].

Questão 4c – Augmentation básica vs. agressiva. A política agressiva reduziu a acurácia em 0,30 p.p. frente ao *baseline* (89,83% vs. 90,13%). Transformações de maior intensidade sobre imagens já de resolução reduzida (96×96) tendem a distorcer características estruturais relevantes, introduzindo ambiguidade no sinal de supervisão.

Estratégia 5 – EfficientNetV2B0. O EfficientNetV2B0 atingiu 89,05%, posicionando-se entre as Estratégias 3 e 4 sem qualquer otimização específica. A resolução de entrada utilizada (96×96) é inferior à recomendada para a família EfficientNetV2, o que pode ter limitado o desempenho, dado que camadas profundas recebem mapas de ativação de dimensões reduzidas após sucessivas operações de *downsampling*.

Padrão de confusão por classe. As classes *gato* ($F1 = 81\%$) e *cachorro* ($F1 = 85\%$) apresentaram desempenho consistentemente inferior em todas as estratégias, refletindo a similaridade morfológica entre as duas categorias em imagens de baixa resolução – limitação estrutural do dataset, não de uma arquitetura específica.

4 Conclusão

A melhor acurácia obtida foi de **90,82%** (Estratégia 4, GAP + SGD + *augmentation* básica, macro-F1 = 91%). O *fine-tuning* superou consistentemente o treinamento do zero (+4,63 p.p.) e a extração estática de características (+10,01 p.p. sobre a Estratégia 2 com MobileNetV2), confirmando que o ajuste dos pesos pré-treinados ao domínio-alvo é determinante para a qualidade final do classificador. Dentre as variáveis investigadas na Estratégia 4, o otimizador mostrou o maior impacto isolado (SGD > Adam em 0,71 p.p.), enquanto a escolha da camada de *pooling* teve efeito negligenciável e a *augmentation* agressiva prejudicou o desempenho em relação à política moderada.

Referências

- [1] KRIZHEVSKY, A.; HINTON, G. *Learning multiple layers of features from tiny images*. Technical Report, University of Toronto, 2009.
- [2] WILSON, A. C. et al. The marginal value of momentum for small learning rate SGD. In: *Proceedings of ICLR*, 2017.